

Reguła Hebba – Sprawozdanie 4


Cel ćwiczenia:

Celem ćwiczenia jest poznanie działania reguły Hebba dla sieci jednowarstwowej na przykładzie grupowania liter alfabetu.

Dane uczące i testujące:

Danymi wykorzystywanymi do testowania programu są matryce liter o wymiarach 5x7. Matryce te odwzorowują ciągi zer i jedynek w jednej linii pliku tekstowego.


Przykładowe matryce:



Uczenie bez nauczyciela

Podczas uczenia bez nauczyciela, pożądana odpowiedź nie jest znana. Sieć sama musi uczyć się poprzez analizę reakcji na pobudzenia (o których naturze wie mało albo nic).

Reguła uczenia bez nauczyciela



$$r = y_i = f(\mathbf{w}_i^T \mathbf{x})$$

Korekta wektora wag:

$$\Delta \mathbf{w}_i = c y_i \mathbf{x} = c f(\mathbf{w}_i^T \mathbf{x}) \mathbf{x}$$

$$\mathbf{w}_i(k+1) = \mathbf{w}_i(k) + \Delta \mathbf{w}_i = \mathbf{w}_i(k) + c y_i \mathbf{x}$$

Z reguły tej wynika, że dodatnia wartość składnika korelacyjnego $y_i x_j$ powoduje wzrost wagi w_{ij} , a w konsekwencji silniejszą reakcję neuronu przy kolejnej prezentacji tego samego obrazu wejściowego.

Często powtarzające się obrazy wejściowe dają więc silniejszą odpowiedź na wyjściu.

Regułę uczenia Hebba nazywa się także niekiedy uczeniem *korelacyjnym* ("correlation learning"). Zmierza do takiego dopasowania wag aby uzyskać najlepszą korelację pomiędzy sygnałami wejściowymi, a zapamiętanym w formie wartości wag "wzorcem sygnału", na który określony neuron ma reagować.

Algorytm działania programu:

- 1) Wczytanie danych uczących i testujących z pliku.
- 2) Ustalenie losowych wag dla każdego neurona.
- 3) Następnie rozpoczyna się proces uczenia
- 4) Dla każdej danej uczącej:
 - ustawiamy błąd na 0.
 - zapamiętujemy w zmiennej pomocniczej wynik poprzedniej operacji
 - liczymy wartość na wyjściu nerona
 - modyfikujemy wagi
 - liczymy błędy
- 5) Sprawdzamy czy błąd jest mniejszy od 0,1 oraz czy liczba epok nie przekracza 1000. Jeśli warunki są nie spełnione powrót do pkt 3.
- 6) Po poprawnym uczeniu rozpoczyna się test.

Budowa sieci:

Warstwa wejściowa mojej sieci składa się z 35 sygnałów wejściowych każdy sygnał odpowiada stanowi 1 pola w matrycy. Sygnał może mieć wartość 0 lub 1 w zależności czy pole jest pełne czy puste.

Istnieje 1 warstwa składająca się z 26 neuronów. Neurony te posiadają losowo wygenerowane wagi a wejść jest 35. Każdy neuron przyporządkowany jest 1 grupie. Zawraca on procentowe podobieństwo badanej litery do grupy reprezentującej przez neuron.

Opracowanie wyników

- Współczynnik zapominania: 0,1


Współczynnik zapominania: 0,1	
Współczynnik uczenia	Liczba epok
0,01	9
0,1	29
0,3	37
0,5	54
0,7	567
1	4681



- Współczynnik zapominania: 0,3

Współczynnik zapominania: 0,3	
Współczynnik uczenia	Liczba epok
0,01	4
0,1	19
0,3	46
0,5	71
0,7	5642
1	8647

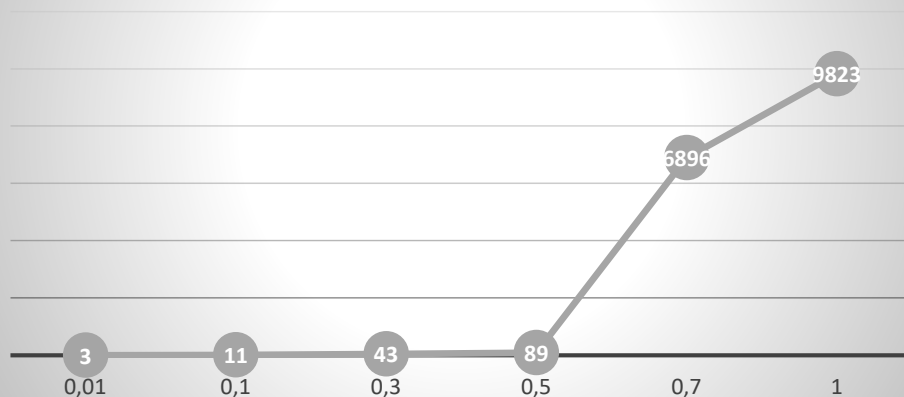
Wykres zależności współczynnika uczenia od liczby epok



- Współczynnik zapominania: 0,5

Współczynnik zapominania: 0,5	
Współczynnik uczenia	Liczba epok
0,01	3
0,1	11
0,3	43
0,5	89
0,7	6896
1	9823

Wykres zależności współczynnika uczenia od liczby epok



Na powyższych wykresach i tabelach widzimy jak współczynnik zaopminania wpływa na proces uczenia. Dla każdego współczynnika wykres ma podobny charakter, jednakże wraz ze wzrostem współczynnika zapominania proces uczenia wydłuża się. Najlepszy rezultat uczenia uzyskano dla współczynnika zapominania równego 0,1.

Następnie przetestowano rozpoznawanie liter C oraz H.

Dla każdej litery wykonano po trzy testy i sprawdzono wyniki.

Parametry dla tego testu to współczynnik zapominania:0,1 oraz współczynnik uczenia:0,5

A: 65%	A: 71%	A: 60%
B: 65%	B: 65%	B: 65%
C: 80%	C: 80%	C: 80%
D: 71%	D: 77%	D: 77%
E: 60%	E: 54%	E: 60%
F: 65%	F: 60%	F: 54%
G: 68%	G: 74%	G: 74%
H: 51%	H: 68%	H: 57%
I: 68%	I: 51%	I: 62%
J: 77%	J: 71%	J: 71%
K: 48%	K: 54%	K: 48%
L: 62%	L: 68%	L: 74%
M: 51%	M: 68%	M: 57%
N: 51%	N: 68%	N: 57%
O: 77%	O: 82%	O: 82%
P: 62%	P: 62%	P: 51%
Q: 68%	Q: 74%	Q: 74%
R: 54%	R: 54%	R: 42%
S: 74%	S: 68%	S: 68%
T: 62%	T: 51%	T: 51%
U: 62%	U: 80%	U: 80%
V: 51%	V: 74%	V: 68%
W: 60%	W: 71%	W: 71%
X: 51%	X: 51%	X: 40%
Y: 48%	Y: 54%	Y: 48%
Z: 62%	Z: 51%	Z: 51%

Jak widać, litera C została rozpoznana poprawnie, jednakże widzimy iż program bardzo często przyporządkowywał ją do litery O.

Testy dla litery H.

A:	68%
B:	57%
C:	54%
D:	51%
E:	62%
F:	68%
G:	54%
H:	77%
I:	42%
J:	51%
K:	68%
L:	65%
M:	65%
N:	65%
O:	57%
P:	65%
Q:	54%
R:	62%
S:	54%
T:	48%
U:	65%
V:	71%
W:	62%
X:	54%
Y:	57%
Z:	42%

C:	60%
D:	62%
E:	62%
F:	74%
G:	71%
H:	82%
I:	42%
J:	62%
K:	68%
L:	65%
M:	71%
N:	77%
O:	62%
P:	71%
Q:	54%
R:	62%
S:	65%
T:	54%
U:	77%
V:	77%
W:	74%
X:	65%
Y:	68%
Z:	54%

A:	74%
B:	62%
C:	54%
D:	62%
E:	68%
F:	74%
G:	65%
H:	88%
I:	37%
J:	57%
K:	74%
L:	71%
M:	77%
N:	82%
O:	57%
P:	71%
Q:	54%
R:	68%
S:	60%
T:	48%
U:	71%
V:	71%
W:	68%
X:	71%
Y:	62%
Z:	60%

Na zrzutach ekranu widzimy poprawne rozpoznanie litery H.

Wnioski:

- Współczynnik uczenia ma duży wpływ na proces uczenia. Najlepsze rezultaty daje współczynnik około 0,5, ponieważ mniejszy powoduje zbyt szybkie uczenie, a współczynniki bliższe wartości 1 mogą powodować nieskończone uczenie
- Współczynnik zapominania również wpływa na jakość uczenia – najlepsze efekty uzyskano dla współczynnika 0,1. Dla większych współczynników rezultaty były gorsze
- Sieć Hebba klasyfikuje obiekty o podobnych cechach, co widzimy na przykładzie testu rozpoznawania litery C. Była ona poprawnie przyporządkowana do grupy 'C', jednakże niewiele gorszy wynik otrzymano dla przyporządkowania do litery 'O', ponieważ te dwie litery są do siebie podobne.

Źródła:

- notatki z wykładów
- https://en.wikipedia.org/wiki/Hebbian_theory
- <http://uhaweb.hartford.edu/compsci/neural-networks-hebb-rule.html>